TD1 : Règles d'Association - Correction Détaillée

Table of Contents

- Exercice 1 : Application de l'algorithme Apriori
- Exercice 2 : Analyse de paniers d'achats d'une librairie
- Conclusion

Ce document présente la correction complète du TD1 sur les règles d'association, comprenant deux exercices pratiques utilisant les algorithmes Apriori et FP-Growth.

Exercice 1 : Application de l'algorithme Apriori

Données de l'exercice

Base transactionnelle :

- T1: {Stylo, Cahier, Gomme}
- T2: {Stylo, Cahier, Règle}
- T3: {Stylo, Gomme, Règle}
- T4: {Cahier, Gomme, Règle}
- T5: {Stylo, Cahier, Gomme, Règle}

Seuils fixés :

- Support minimum = 2
- Confiance minimum = 70%

1. Étape 1 – Itemsets de taille 1 (C1 et L1)

Candidats C1 :

- {Cahier}: support = 4
- {Gomme}: support = 4
- {Règle}: support = 4
- {Stylo}: support = 4

Itemsets fréquents L1 (support ≥ 2) :

- {Cahier}: support = 4
- {Gomme}: support = 4
- {Règle}: support = 4
- {Stylo}: support = 4

Analyse : Tous les items sont fréquents car ils apparaissent dans au moins 2 transactions.

2. Étape 2 – Itemsets de taille 2 (C2 et L2)

Candidats C2 :

- {Cahier, Gomme}: support = 3
- {Cahier, Règle}: support = 3
- {Cahier, Stylo}: support = 3
- {Gomme, Règle}: support = 3
- {Gomme, Stylo}: support = 3
- {Règle, Stylo}: support = 3

Itemsets fréquents L2 (support ≥ 2) :

- {Cahier, Gomme}: support = 3
- {Cahier, Règle}: support = 3
- {Cahier, Stylo}: support = 3
- {Gomme, Règle}: support = 3
- {Gomme, Stylo}: support = 3
- {Règle, Stylo}: support = 3

Analyse : Tous les 2-itemsets sont fréquents, montrant une forte corrélation entre tous les produits.

3. Étape 3 – Itemsets de taille 3 (C3 et L3)

Candidats C3 :

- {Cahier, Gomme, Stylo}: support = 2
- {Cahier, Règle, Stylo}: support = 2
- {Cahier, Gomme, Règle}: support = 2
- {Gomme, Règle, Stylo}: support = 2

Itemsets fréquents L3 (support ≥ 2) :

- {Cahier, Gomme, Règle}: support = 2
- {Cahier, Gomme, Stylo}: support = 2
- {Cahier, Règle, Stylo}: support = 2
- {Gomme, Règle, Stylo}: support = 2

4. Étape 4 – Itemsets de taille 4

Candidat C4 :

- {Cahier, Gomme, Règle, Stylo}: support = 1

Résultat : Aucun itemset fréquent de taille 4 (support < 2)

Justification :

- Le 4-itemset {Cahier, Gomme, Règle, Stylo} n'apparaît que dans T5
- Son support (1) est inférieur au seuil minimum (2)
- L'algorithme s'arrête car aucun itemset plus grand ne peut être fréquent

5. Analyse finale

Itemsets fréquents trouvés :

- L1: 4 itemsets (tous les items individuels)
- L2: 6 itemsets (toutes les paires possibles)
- L3: 4 itemsets (combinaisons de 3 items)
- L4: Aucun

Pourquoi l'algorithme s'arrête :

1. Aucun itemset de taille 4 n'atteint le seuil de support minimum
2. Selon le principe d'Apriori : si aucun k-itemset n'est fréquent, alors aucun (k+1)-itemset ne peut être fréquent
3. Il devient inutile de continuer la recherche

6. Génération des règles d'association (confiance ≥ 70%)

Règles générées (12 règles au total) :

À partir de L2 :

1. {Gomme} → {Cahier} : support=3, confiance=75%
2. {Cahier} → {Gomme} : support=3, confiance=75%
3. {Règle} → {Cahier} : support=3, confiance=75%
4. {Cahier} → {Règle} : support=3, confiance=75%
5. {Stylo} → {Cahier} : support=3, confiance=75%
6. {Cahier} → {Stylo} : support=3, confiance=75%
7. {Règle} → {Gomme} : support=3, confiance=75%
8. {Gomme} → {Règle} : support=3, confiance=75%
9. {Stylo} → {Gomme} : support=3, confiance=75%
10. {Gomme} → {Stylo} : support=3, confiance=75%
11. {Règle} → {Stylo} : support=3, confiance=75%
12. {Stylo} → {Règle} : support=3, confiance=75%

Interprétation : Toutes les règles ont une confiance de 75%, indiquant une forte association entre tous les produits de papeterie.

Exercice 2 : Analyse de paniers d'achats d'une librairie

Données de l'exercice

Base de transactions :

- T1: {Livre_Roman, Livre_Sciences, Stylo, Cahier}
- T2: {Livre_Sciences, Magazine, Stylo}
- T3: {Livre_Roman, Cahier, Agenda}
- T4: {Livre_Sciences, Livre_Roman, Magazine, Cahier}
- T5: {Livre_Roman, Stylo, Agenda}
- T6: {Livre_Sciences, Cahier, Stylo, Agenda}
- T7: {Livre_Roman, Livre_Sciences, Stylo}

- T8: {Livre_Sciences, Magazine, Cahier}

Seuils :

- Support minimum = 3
- Confiance minimum = 60%

1. Apriori - Génération des itemsets fréquents

1-itemsets

Support de chaque item :

- {Agenda}: 3 ✓ Fréquent
- {Cahier}: 5 ✓ Fréquent
- {Livre_Roman}: 5 ✓ Fréquent
- {Livre_Sciences}: 6 ✓ Fréquent
- {Magazine}: 3 ✓ Fréquent
- {Stylo}: 5 ✓ Fréquent

2-itemsets

Candidats C2 et leur fréquence :

- {Agenda, Cahier}: 2 ✗
- {Agenda, Livre_Roman}: 2 ✗
- {Agenda, Livre_Sciences}: 1 ✗
- {Agenda, Magazine}: 0 ✗
- {Agenda, Stylo}: 2 ✗
- {Cahier, Livre_Roman}: 3 ✓
- {Cahier, Livre_Sciences}: 4 ✓
- {Cahier, Magazine}: 2 ✗
- {Cahier, Stylo}: 2 ✗
- {Livre_Roman, Livre_Sciences}: 3 ✓
- {Livre_Roman, Magazine}: 1 ✗
- {Livre_Roman, Stylo}: 3 ✓
- {Livre_Sciences, Magazine}: 3 ✓
- {Livre_Sciences, Stylo}: 4 ✓
- {Magazine, Stylo}: 1 ✗

Itemsets fréquents L2 (6 itemsets) :

- {Cahier, Livre_Roman}: support = 3
- {Cahier, Livre_Sciences}: support = 4
- {Livre_Roman, Livre_Sciences}: support = 3
- {Livre_Roman, Stylo}: support = 3
- {Livre_Sciences, Magazine}: support = 3
- {Livre_Sciences, Stylo}: support = 4

3-itemsets

Candidats C3 :

- {Livre_Sciences, Magazine, Stylo}: 1 ✗
- {Cahier, Livre_Roman, Livre_Sciences}: 2 ✗
- {Livre_Roman, Livre_Sciences, Stylo}: 2 ✗

Résultat : Aucun itemset fréquent de taille 3 (tous ont support < 3)

2. Apriori - Règles d'association (confiance ≥ 60%)

Règles trouvées (10 règles triées par confiance) :

1. {Magazine} → {Livre_Sciences} : support=3, confiance=100%
2. {Cahier} → {Livre_Sciences} : support=4, confiance=80%
3. {Stylo} → {Livre_Sciences} : support=4, confiance=80%
4. {Livre_Sciences} → {Cahier} : support=4, confiance=67%
5. {Livre_Sciences} → {Stylo} : support=4, confiance=67%
6. {Livre_Roman} → {Cahier} : support=3, confiance=60%
7. {Cahier} → {Livre_Roman} : support=3, confiance=60%
8. {Livre_Roman} → {Livre_Sciences} : support=3, confiance=60%
9. {Livre_Roman} → {Stylo} : support=3, confiance=60%
10. {Stylo} → {Livre_Roman} : support=3, confiance=60%

Interprétations principales :

- **{Magazine} → {Livre_Sciences} (100%)** : Les clients achetant des magazines achètent toujours des livres de sciences
- **{Cahier} → {Livre_Sciences} (80%)** : Forte association entre cahiers et livres scientifiques (prise de notes)
- **{Stylo} → {Livre_Sciences} (80%)** : Les stylos sont souvent achetés avec des livres scientifiques

3. Algorithme FP-Growth

Étape 1 : Fréquences des items (triées par ordre décroissant)

- Livre_Sciences: 6
- Cahier: 5
- Livre_Roman: 5
- Stylo: 5
- Agenda: 3
- Magazine: 3

Étape 2 : Transactions réorganisées

- T1: [Livre_Sciences, Cahier, Livre_Roman, Stylo]
- T2: [Livre_Sciences, Stylo, Magazine]
- T3: [Cahier, Livre_Roman, Agenda]
- T4: [Livre_Sciences, Cahier, Livre_Roman, Magazine]
- T5: [Livre_Roman, Stylo, Agenda]

- T6: [Livre_Sciences, Cahier, Stylo, Agenda]
- T7: [Livre_Sciences, Livre_Roman, Stylo]
- T8: [Livre_Sciences, Cahier, Magazine]

Étape 3 : Construction de l'arbre FP

Structure de l'arbre :

```
Racine (null)
└─ Cahier:1
   └─ Livre_Roman:1
      └─ Agenda:1
└─ Livre_Roman:1
   └─ Stylo:1
      └─ Agenda:1
└─ Livre_Sciences:6
   └─ Cahier:4
      └─ Livre_Roman:2
         └─ Magazine:1
         └─ Stylo:1
      └─ Magazine:1
      └─ Stylo:1
         └─ Agenda:1
   └─ Livre_Roman:1
      └─ Stylo:1
   └─ Stylo:1
      └─ Magazine:1
```

Étape 4 : Extraction des itemsets fréquents

Itemsets fréquents trouvés par FP-Growth :

1-itemsets :

- {Livre_Sciences}: support = 6
- {Cahier}: support = 5
- {Livre_Roman}: support = 5
- {Stylo}: support = 5
- {Agenda}: support = 3
- {Magazine}: support = 3

2-itemsets :

- {Cahier, Livre_Sciences}: support = 4
- {Livre_Sciences, Stylo}: support = 4
- {Cahier, Livre_Roman}: support = 3
- {Livre_Roman, Livre_Sciences}: support = 3
- {Livre_Roman, Stylo}: support = 3
- {Livre_Sciences, Magazine}: support = 3

4. Comparaison Apriori vs FP-Growth

Différences dans la méthode

Apriori :

- Approche niveau par niveau (breadth-first)
- Génère explicitement tous les candidats
- Nécessite plusieurs parcours de la base
- Peut générer des candidats inutiles

FP-Growth :

- Approche divide-and-conquer (depth-first)
- Construit une structure compacte (arbre FP)
- Ne génère pas de candidats explicitement
- Seulement 2 parcours de la base de données

Quand FP-Growth est plus avantageux

1. **Grandes bases de données** : Moins de parcours nécessaires
2. **Support minimum faible** : Pas de génération excessive de candidats
3. **Transactions longues** : Compression efficace via les préfixes communs
4. **Motifs fréquents longs** : Plus rapide pour les découvrir

Quand Apriori est préférable

- Base de données très petite
- Support minimum très élevé
- Contraintes de mémoire importantes

Comparaison des résultats

Résultats identiques :

- Apriori : 6 (1-itemsets) + 6 (2-itemsets) = 12 itemsets
- FP-Growth : 6 (1-itemsets) + 6 (2-itemsets) = 12 itemsets

✅ **Les deux algorithmes trouvent les MÊMES itemsets fréquents !**

La différence réside dans la **méthode de découverte**, pas dans le **résultat final**.

Conclusion

Ce TD illustre parfaitement les deux approches principales pour la découverte de règles d'association :

- **Apriori** reste intuitif et facile à comprendre, mais peut être inefficace sur de grandes bases
- **FP-Growth** offre de meilleures performances dans la plupart des cas réels

Les deux algorithmes garantissent de trouver **tous** les itemsets fréquents et les règles d'association correspondantes, mais FP-Growth le fait généralement de manière plus efficiente.

Dans les applications pratiques, le choix entre ces algorithmes dépend principalement de :

- La taille de la base de données

- La valeur du support minimum
- Les ressources disponibles (mémoire, temps de calcul)

Les règles d'association découvertes peuvent être utilisées pour :

- Recommandations de produits
- Optimisation de l'agencement en magasin
- Stratégies de marketing croisé
- Analyse des comportements d'achat